YunTAPR-Net：首批消融结果与复现准备

seed2026，2024 开发集探索性分析

研究者审查稿：基于冻结实验及已发布聚合证据

2026 年 10 月 17 日

摘要

本报告审查 B0/B1 与 E0/E1/E2 的六个固定第九轮终点，不新增模型推理或优化器更新。E1 在两个模型上降低 Brier 和十箱可靠性偏差，排序指标变化远小于概率误差变化。E2 的 q32 覆盖改善主要得到 B0 的开发集证据支持，B1 的探索区间跨零；所有组仍欠覆盖。B1 的总体排序与条件 Pinball 较好，但最高雨强层和上尾诊断不支持全面优越性。六份最终 LAST 的内容 SHA 与收据一致；本轮允许范围的跨盘搜索未核验到独立备份。全部结论限于已反复使用的 2024 开发集及单个初始化 seed，不能解释为独立确认结果。

1 数据、设计与证据口径

固定矩阵为 B0-Matched-v2（最新一帧 B13）和 B1-v2（六帧因果 B13），E0：$\alpha = 0.5, \gamma = 2, \lambda_q = 1$；E1：$\gamma = 0$，其余同 E0；E2：$\lambda_q = 2$，其余同 E0。seed 均为 2026，沿用 D1/Q1/N0/I3/B9/S0/V0。每组固定 9 epoch、47,052 次已提交更新，六组合计 282,312 次有效预算内终点更新；历史失败或重放消耗不能由此抹除，完整消耗继续以原持久化账本为准。2023 Train 为 10,455 场景；2024 Development 为共同 10,501 场景。每组第九轮有效暴露 $N_v = 36,018,430$，真实有雨暴露 $N_r = 4,496,600$。场景–像元暴露不是独立事件；冻结日期为 3–10 月窗口，不代表完整四季。2024 已用于历史 BEST 选择及反复诊断，2025 独立测试继续封存。

输入标签由原始 FP32 雨强严格大于 0.1 mm/h 判定；条件分位数计算在 FP64 的 $\log(1+\mathrm{mm/h})$ 空间。32 个 $\tau_i = (i-0.5)/32$，最高 $\tau_{32} = 0.984375$。令 ℓ_γ 为保留 $\alpha = 0.5$ 的 Focal，$\rho_\tau(u) = \max(\tau u, (\tau-1)u)$。

$$S_{\mathrm{occ},\gamma} = \sum_{j \in V} \tfrac{1}{2}(1-p_{t,j})^{\gamma}\,\mathrm{BCEWithLogits}(z_j, y_j), \tag{1}$$

$$S_q = \sum_{j \in R} \frac{1}{32} \sum_{i=1}^{32} \rho_{\tau_i}\left(\log(1+r_j) - q_{ij}\right), \tag{2}$$

$$L_{\mathrm{train}} = (S_{\mathrm{occ},\gamma} + \lambda_q S_q)/N_v, \tag{3}$$

$$\mathrm{CommonCore}_{64} = (S^{64}_{\mathrm{occ},2} + S^{64}_q)/N_v, \qquad \mathrm{CP} = S^{64}_q/N_r. \tag{4}$$

因此 E1 仍是 0.5× BCE，且三个臂的训练 loss 不可直接当作共同评价。CP 未乘 λ_q。Common Core 固定 $\gamma = 2$，并非 E1 的训练目标。Brier 为 $\sum_V (p-y)^2/N_v$；AUROC/AP 使用已发布的精确 score 并列规则，十箱可靠性不替代排序计算。覆盖率只对真实有雨有效像元统计。

代码映射：上述训练和共同评价分别来自候选 `phase_b_v2_ablations/focal.py`、`pinball.py`、`total.py`、`metrics.py`；可靠性、精确并列分数与雨强层来自 `phase_b_v2_formal_integration_candidate/metrics.py`。具体函数和源码 SHA 见随附 `manifest.json`，不修改正式源码。

2 固定第九轮结果

模型/臂	Brier	AUROC	AP	Common Core	CP	q32 覆盖 (%)
B0/E0	0.096868	0.886357	0.567233	0.048760	0.124885	95.744
B1/E0	0.095253	0.893469	0.585905	0.047816	0.124113	95.077
B0/E1	0.075428	0.885215	0.566025	0.075546	0.126308	95.743
B1/E1	0.073169	0.893573	0.587419	0.076413	0.124430	95.161
B0/E2	0.097503	0.886222	0.565541	0.048811	0.125368	96.076
B1/E2	0.093712	0.894195	0.587372	0.047644	0.123452	95.157

表中概率误差和排序指标无量纲；CP 在 $\log(1+\mathrm{mm/h})$ 空间，Common Core 是混合目标，不标为雨强单位。未进行基于结果的最佳轮次选择。图 1 显示训练与共同评价，图 2 显示完整开发曲线。E1 的 Common Core 明显较高，不应为突出 Brier 改善而省略这一代价。总体训练目标下降及开发指标波动只能描述这九轮，不证明收敛或无过拟合。

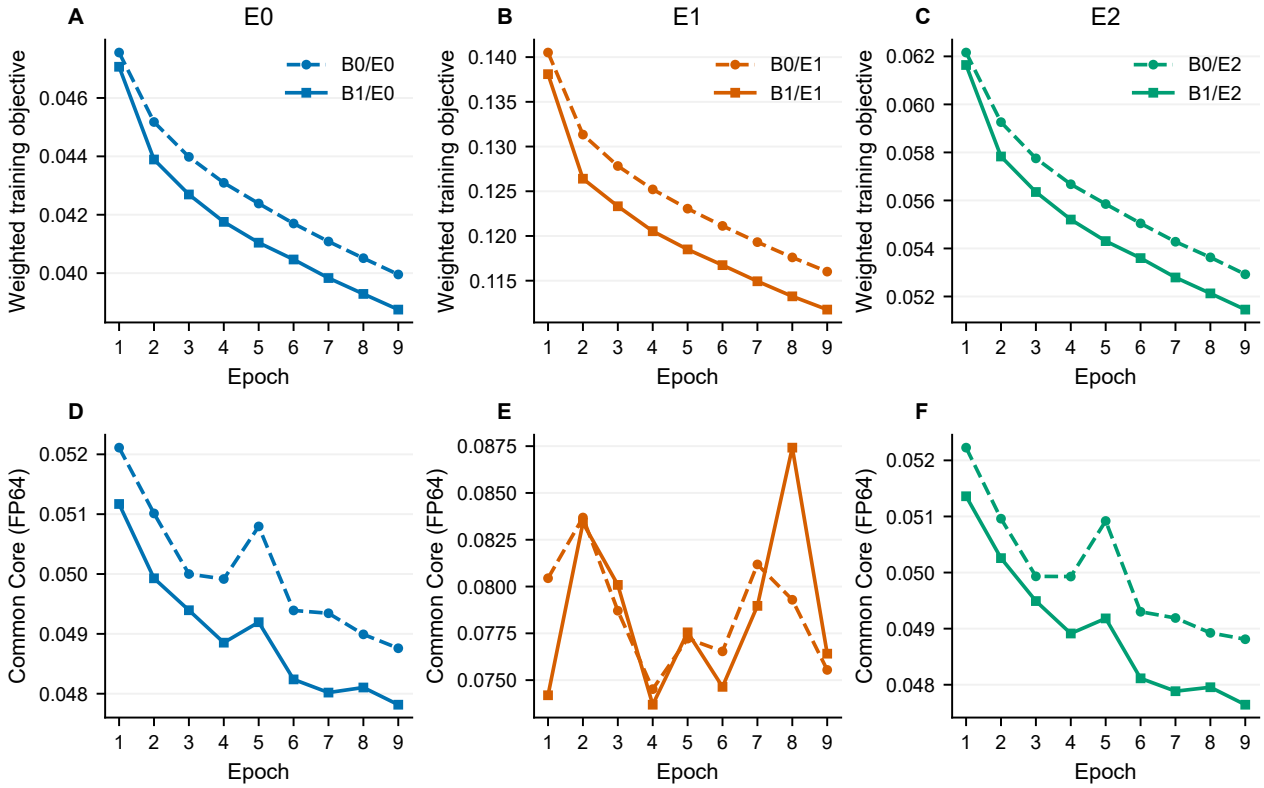


图 1: 九轮曲线。上排为各臂不同的训练目标，下排为统一 FP64 Common Core；不同面板纵轴独立。

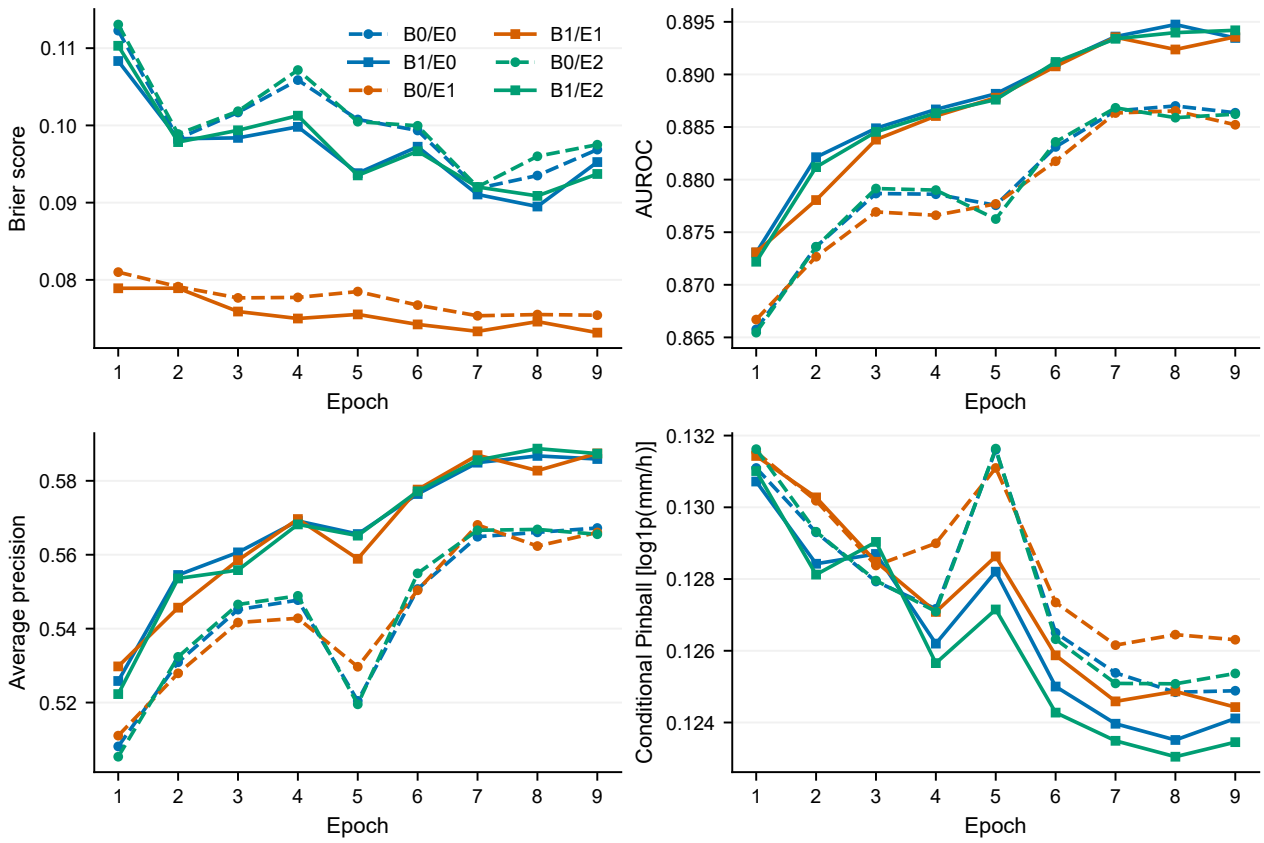


图 2: 六组完整开发曲线。实线 B1、虚线 B0；仅报告固定第九轮，不据开发表现改变预算。

3 四个预注册主比较与 M-C 复核

H-O 主效应为 E1−E0 的 Brier 差；H-Q 为 E2−E0 的 $|\widehat{C}_{32} - 0.984375|$ 差。两类效应均以负值为有利方向。

模型	对比/指标	点估计	95% 探索区间
B0	E1/E0 Brier	-0.021440	[-0.024515, -0.018641]
B0	E2/E0 覆盖绝对误差 (pp)	-0.332162	[-0.431619, -0.236415]
B1	E1/E0 Brier	-0.022084	[-0.024863, -0.019584]
B1	E2/E0 覆盖绝对误差 (pp)	-0.080016	[-0.229909, +0.063129]

保留 35 个固定 UTC 七日非重叠日期块，PCG64 seed=2026，2,000 次配对有放回抽样。每次对所有对比使用同一组块 multiplicities，先合计分子、分母再取比值，不平均各块指标，也不把 seed× 像元当独立样本。q32 每次重采样重新取绝对误差后作差。采用 NumPy linear 分位数的 2.5% 和 97.5% 百分位区间。已独立复算抽样矩阵 SHA、四个点估计和区间，并用逐抽样直接汇总再次检查矩阵算法。54 份 epoch 验证收据 SHA、六组样本/日期块身份及同轮训练顺序均一致。

这些是四个逐项探索区间，不是同时区间，未施加确认性多重比较控制，不输出显著性星号或功效保证。跨周天气过程相关和季节非平稳仍可能使区间低估不确定性。H-O 在两模型中有一致开发性方向证据；H-Q 的 B0 区间位于改善方向，B1 区间跨零。尚未建立科学最小有意义效应或副作用容忍值，不能据区间位置直接宣告科学验收通过。

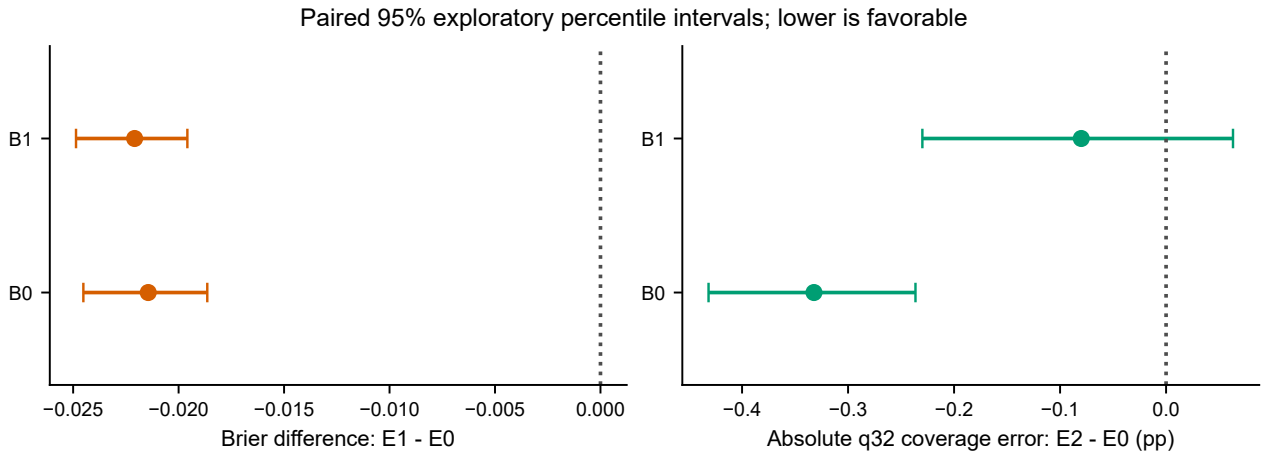


图 3: 四个预注册主比较。覆盖误差用百分点 (pp)；区间为配对日期块开发性区间，非确认性结论。

4 E1：概率误差与可靠性

E1 在 B0/B1 的 Brier 分别下降约 0.02144/0.02208，但 AUROC/AP 变化较小。冻结十箱揭示 E0 低至中概率范围的高估，以及较高概率范围的低估；E1 更接近可靠性对角线。实际有雨比例为 12.484%，E0 平均预测概率约为 25%，E1 则接近 12%。因此此处的改善主要体现在概率数值及其可靠性，而非同等幅度的排序提升。不能由此认定所有概率区间均已校准，或已经获得未来年份泛化能力。

为便于描述，额外计算十箱 ECE：$\sum_k n_k|\bar{p}_k - \bar{y}_k|/N_v$。它不是新增预注册主指标，也不是不依赖分箱的校准真值；不据此重新选择臂或阈值。

模型/臂	平均预测概率	实际频率	均值偏差	描述性 ECE10
B0/E0	0.249738	0.124842	0.124896	0.135987
B1/E0	0.251961	0.124842	0.127119	0.137958
B0/E1	0.126479	0.124842	0.001638	0.005284
B1/E1	0.121967	0.124842	-0.002874	0.008223
B0/E2	0.252184	0.124842	0.127342	0.138263
B1/E2	0.246774	0.124842	0.121933	0.134587

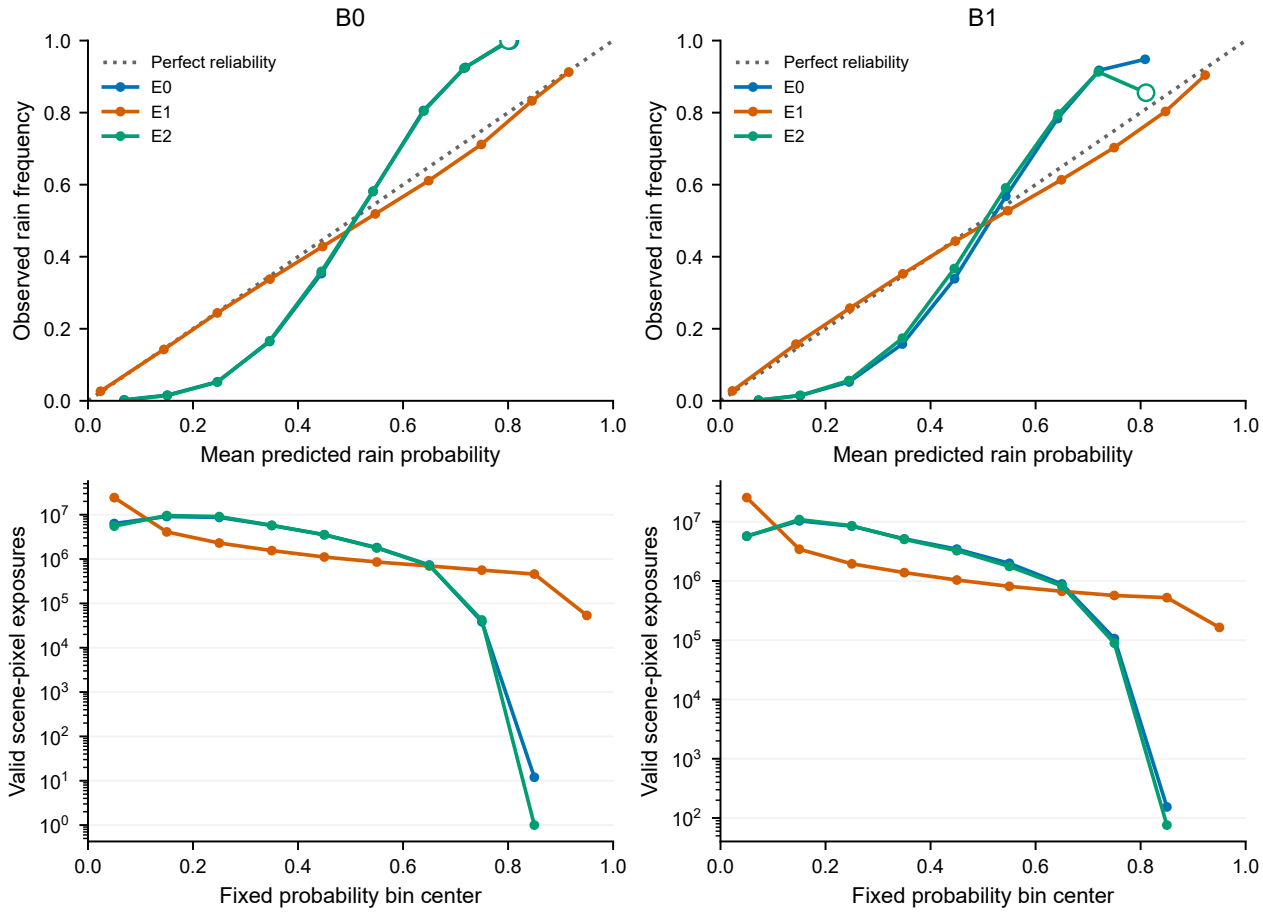


图 4: 冻结十箱可靠性及暴露数。空箱不插值，少于 100 暴露的点以空心仅作绘图提示；该提示不改变统计规则。

E1 的 CP 在两模型中均略高于 E0，B1 的 q32> 100 暴露由 58 增至 108。这与“发生概率更好必然使强度更好”不一致。共享骨干梯度改变可能影响条件头，但本次结果不能确认该机制；需要预定义种子的复现，不能将猜想写成已证实解释。

5　E2、全部分位数覆盖和上尾

所有臂的 q32 覆盖仍低于 98.4375% 目标。E2 的 B0 从 95.744% 提升到 96.076%，B1 从 95.077% 提升到 95.157%；均未解决欠覆盖。B0 的 E2 CP 反而略升，B1 略降，说明覆盖靠近目标不等于分布质量全面改善。必须联合全部 32 个覆盖率、CP、强雨层及异常上尾判断。

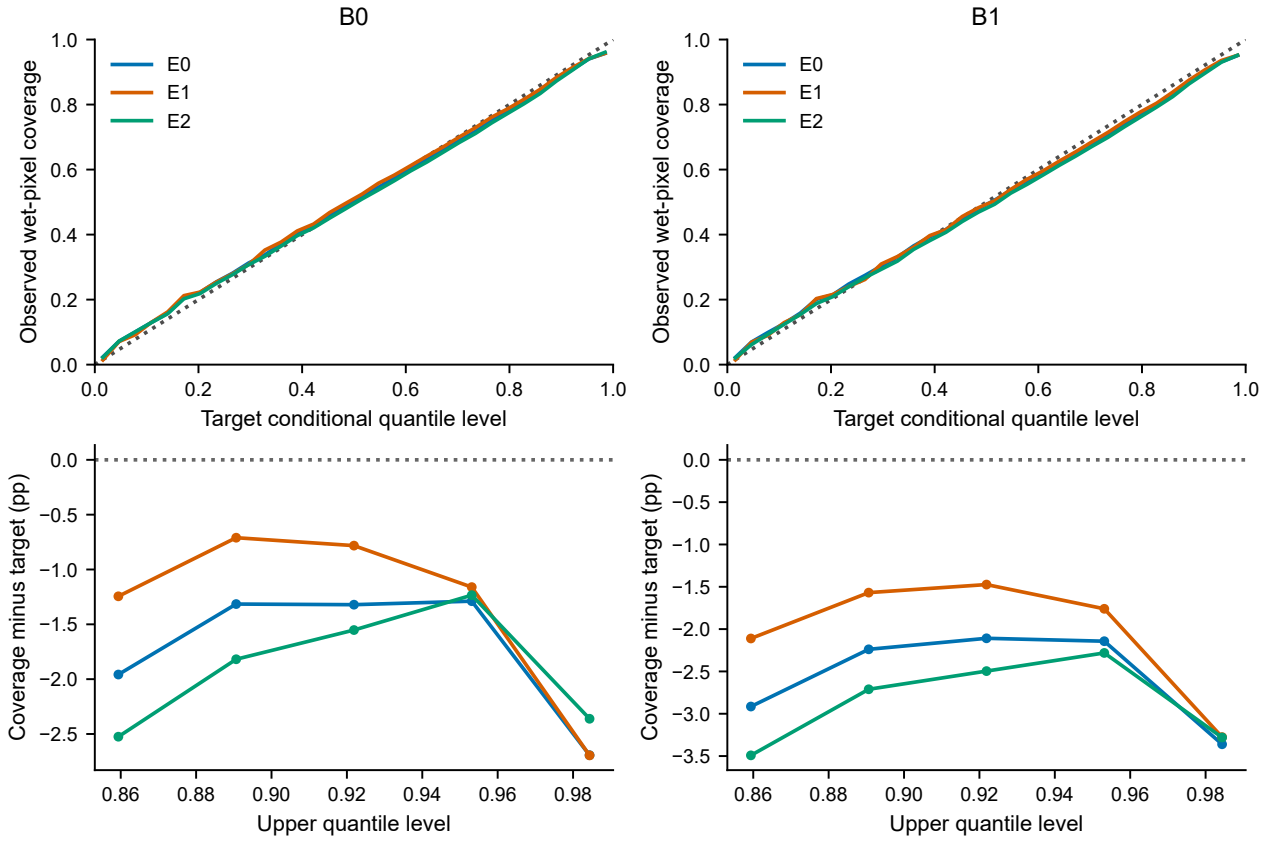


图 5: 全部 32 条件覆盖率及上端分位数偏差。分母均为真实有雨有效暴露；下排为覆盖率减目标的百分点。

模型/臂	q32 最大 (mm/h)	最大 log span	>100 暴露	其中无雨	场景/格点
B0/E0	93.26	4.3413	0	0	0/0
B1/E0	351.08	5.7083	58	28	28/44
B0/E1	86.72	4.1206	0	0	0/0
B1/E1	371.51	5.8250	108	40	48/87
B0/E2	146.51	4.5349	22	0	7/20
B1/E2	262.93	5.3031	57	23	17/36

这里的 span 是 $q_{32}-q_1=\log[(1+Q_{32})/(1+Q_1)]$，不是 mm/h 宽度，也不能把 $\exp(\text{span})-1$ 当作 $Q_{32}-Q_1$。已有聚合证据只保留最大 span，不足以重建完整分布、百分位或逐位置发生概率–q32 联合关系。这些内容记为 NOT_AVAILABLE，不额外运行真实推理填补。

高分位数超过 100 mm/h 的统计是条件分布的场景–像元暴露，不是相同数量的独立暴雨事件或确定性百毫米预报。无雨指 IMERG 参考未超过冻结 0.1 mm/h 标签阈值，不保证独立站点或雷达证实无雨。E2 对两个模型的最大值及暴露影响不同；B0 最大值上升而 B1 下降，不能宣称统一压制上尾。

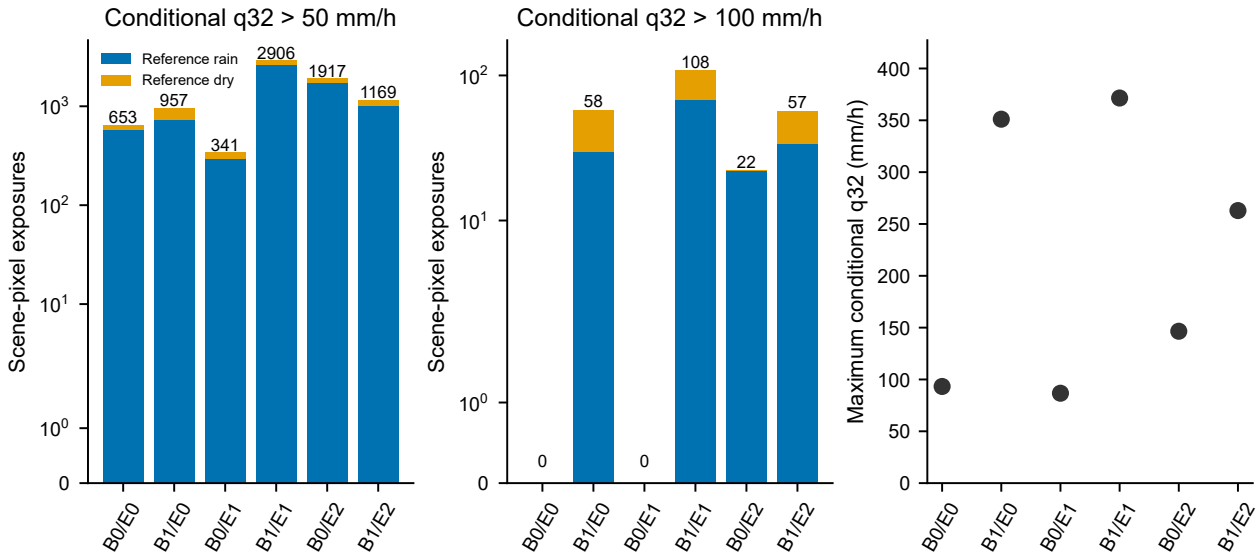


图 6: 固定阈值上尾暴露及最大 q32。阈值计数保留湿/干拆分，不能作为独立事件数或物理验证结论。

6 强雨分层与时序贡献

原定七层 $(0.1,1],(1,5],(5,10],(10,20],(20,30],(30,50],>50$ mm/h，暴露数依次为 2,764,086、1,470,675、207,616、46,735、6,053、1,366、69。总体 CP 主要由低雨强暴露贡献，不能掩盖高雨强误差。B1 相对 B0 在三臂的总体 Brier、AUROC、AP 和 CP 点估计均较好，但 q32 覆盖误差均更大，且在 >50 mm/h 层的 CP 三臂均更高。该层仅 69 个相关暴露，不能据此推断 69 次独立极端事件。E0 在 >5 mm/h 各层的 B1 CP 均高于 B0；E1/E2 的层间变化更复杂。因此“时序信息有贡献”目前只能限定于总体开发性指标，不能推广到全部强度。

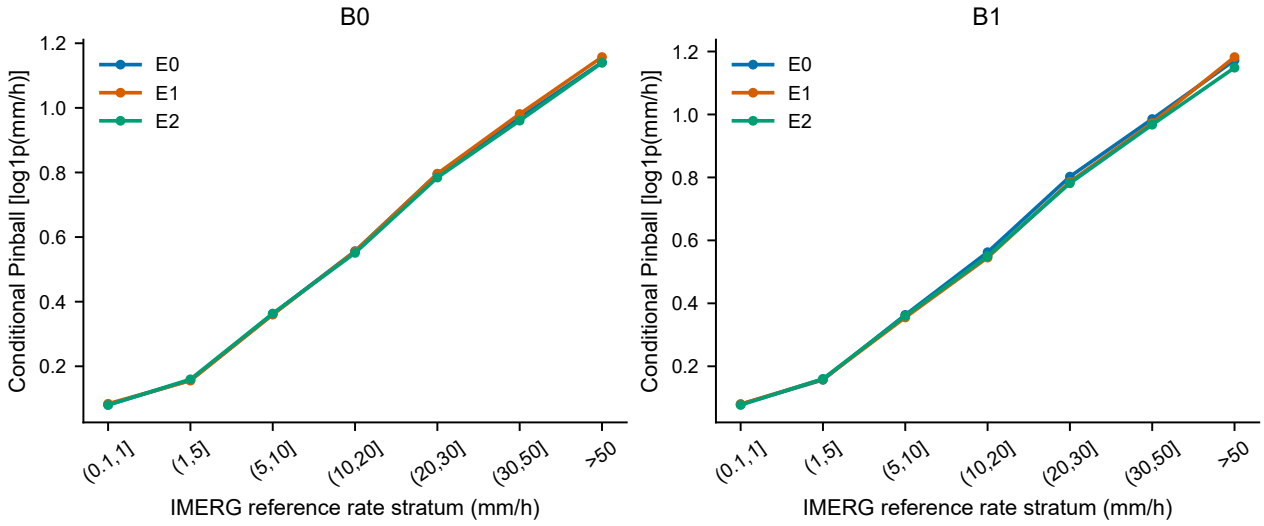


图 7: 冻结七个真实雨强层的条件 Pinball。全层数值见 rain_strata.csv，高雨强小样本需谨慎解释。

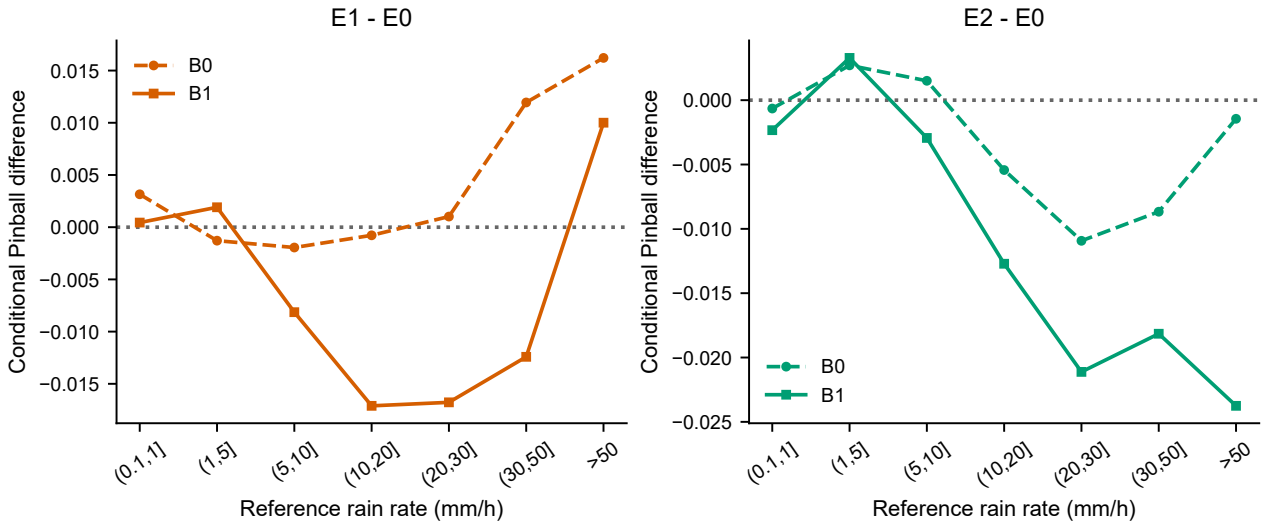


图 8: E1/E2 相对 E0 的分层 CP 变化。负值较小；原始层边界保持不变，未据结果重分层。

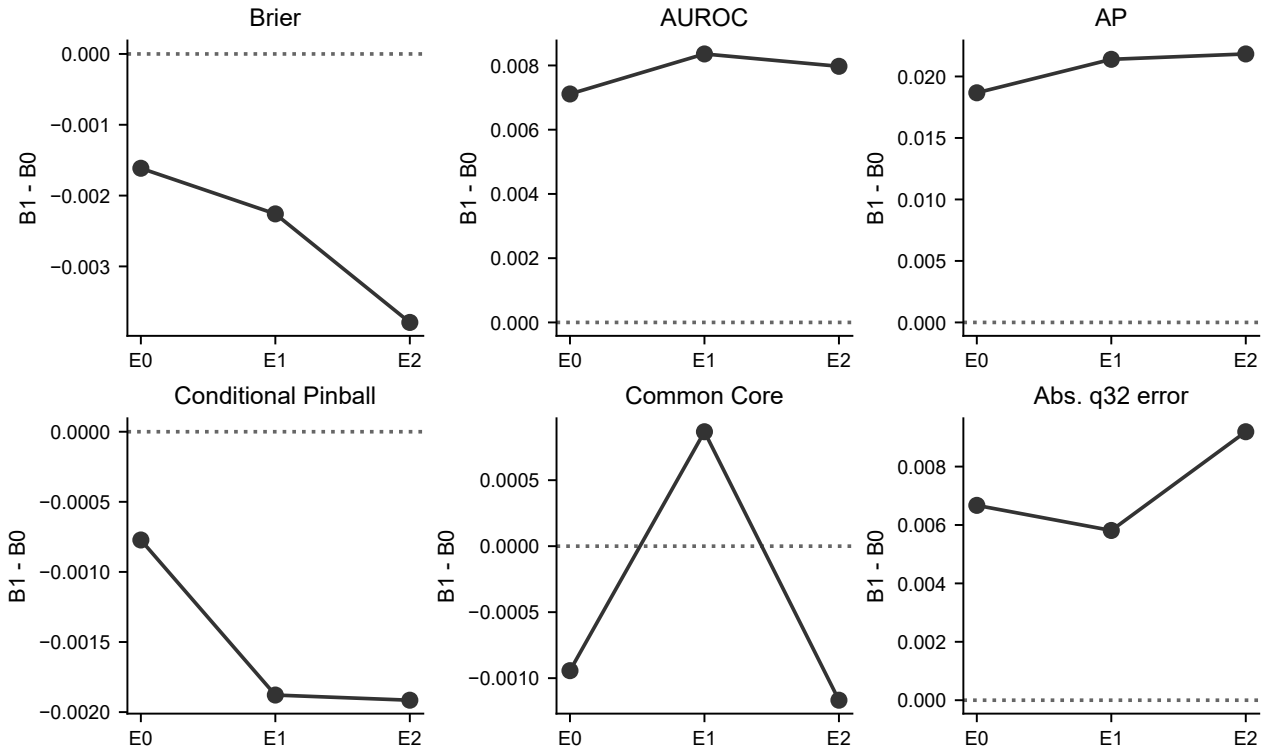


图 9: 各臂 B1 减 B0 的固定终点差异。此图为补充描述，不升级为新确认性交互检验。

7 最终 LAST、备份与复现边界

六份第九轮 payload 使用受控只读句柄逐字节计算 SHA，不反序列化模型。收据、注册记录和发布摘要的 SHA 相符；句柄对象身份及读取前后元数据稳定。共读取 315,858,678 字节，全部匹配。未来消费仍须同字节验证，单次 SHA 不是永久不变性证明。

模型/臂	SHA-256 前 16 位	读取字节	状态
B0_MATCHED_V2/E0	a806db984338abe4	52,623,081	PASS
B1_V2/E0	ead05bd42a7548f6	52,652,009	PASS
B0_MATCHED_V2/E1	d36f6d541245b15b	52,624,233	PASS
B1_V2/E1	b9696c16d69b7b92	52,663,529	PASS
B0_MATCHED_V2/E2	851876e761814b8f	52,633,449	PASS
B1_V2/E2	58bbeb40e5d91efa	52,662,377	PASS

完整 SHA、脱敏路径标识、只读句柄身份见 CHECKPOINT_PAYLOAD_AUDIT.json。在用户授权的 C:–H: 文件名搜索中遍历 102,397 个目录、1,196,779 个条目，拒绝 1,137 个包含 2025 的子项名称，发生 6 处权限拒绝；排除系统/缓存、重解析点。未核验到六份最终 LAST 的独立副本，尤其不能证明离线盘、压缩包或重命名备份存在或不存在。首遍达到 120,000 目录上限后已保留收据，第二遍改为各卷轮询并在允许范围完成。新搜索不对被禁止子路径做主动属性或内容读取；历史 2025 属性访问继续为 NOT_INSTRUMENTED。

备份建议是未来获准执行时，在完整 epoch+ 验证 + 原子 LAST+ 账本提交之后，复制到第二物理卷及离线/版本化位置，再计算目标完整 SHA，匹配后提交备份清单。保留所有第九轮以及每轮事务证据。此分析任务没有自动复制权重或改变账本。

8 剩余十二组的实测资源估算与暂停

组	训练 (h)	验证 (h)	合计 (h)	CUDA allocated/reserved(GiB)
B0/E0	4.53	2.02	6.54	3.26/5.53
B1/E0	8.79	3.87	12.67	3.31/5.54
B0/E1	4.61	2.04	6.64	3.26/5.53
B1/E1	7.66	3.43	11.09	3.30/5.57
B0/E2	5.02	2.24	7.26	3.26/5.53
B1/E2	8.77	9.66	18.43	3.30/5.57

表为已提交九轮路径，重放、启动和异常开销不在每组求和内。B0 每轮训练/验证中位耗时约 30.7/13.3 分钟，B1 约 53.1/23.3 分钟。但 B1/E2 第 5 轮训练约 99.5 分钟、验证约 389.5 分钟，总计约 8.15 小时。异常慢轮原因 NOT_ESTABLISHED，不能无遥测归因为热降频、休眠或 I/O。

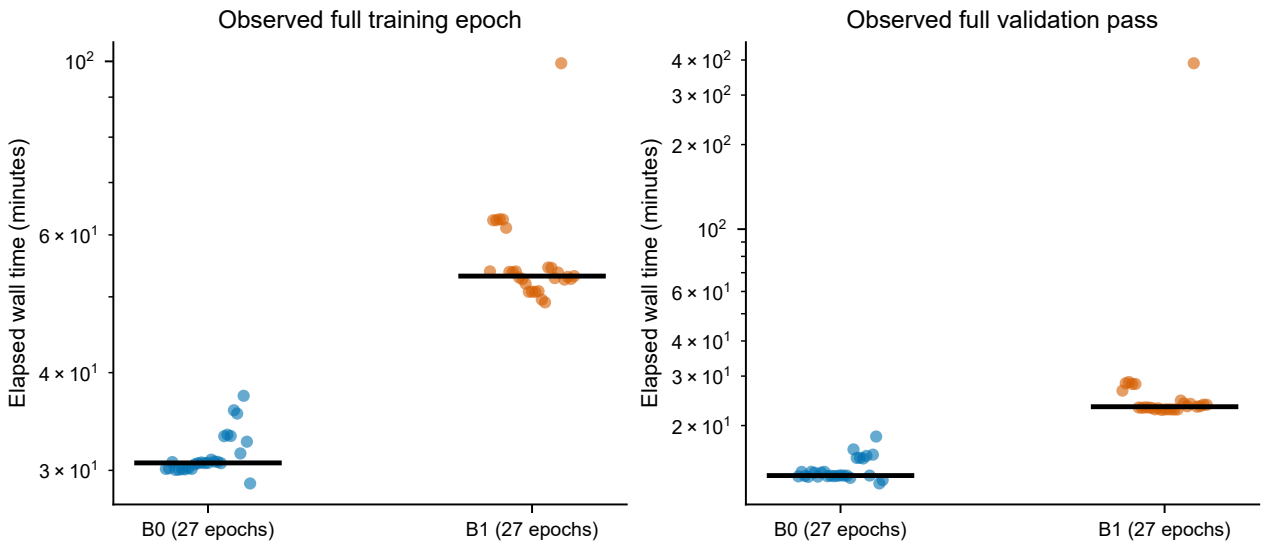


图 10: 已提交 54 轮的实际训练与验证耗时，含慢轮；黑横线为中位数，不是区间。

剩余 12 组项目	估算/观测
计划更新 / epoch	564,624 / 108
完整开发验证场景暴露	1,134,108
已完成六组 train+validation	62.63 h
12 组按每模型实测均值	125.26 h
按历史累计活动时长比例	132.50 h
上述较大值加 25% 规划余量	165.63 h（6.90 天）
预计反复原始内容 I/O	27.66 TiB
108 份 checkpoint payload	5.29 GiB
payload 三份合计	15.88 GiB
审计日志线性估计	7.58 GiB
精确分数暂存实测比例 / 硬预算	0.037 / 27.0 GiB

这些是同类设备单 GPU 被任务占用的墙钟时间，不是 GPU 利用率积分、能耗或 FLOP 测量。实测每轮 P10/P90 线性情景约 105–126 h，但不构成预测或置信区间，且不能包络极慢轮。125 h 核心估计保留慢轮；132.5 h 另按历史累计 66.25 h 的两倍计入已观察开销。166 h 加余量仅是规划假设；未来驱动崩溃、供电、磁盘或可用时间改变均可能超过它。

已观察最大 CUDA allocated/reserved 为 3.31/5.57 GiB；进程 working set 5.26 GiB，采样 private commit 10.18 GiB。working set 与 private commit 不可相加，后者不是物理驻留量。原硬限制仍为 CUDA reserved 6 GiB、启动空闲显存至少 5 GiB，进程 working set 6 GiB、private commit 12 GiB、Job commit 16 GiB，系统空闲 RAM 6 GiB、commit 余量 10 GiB、磁盘余量 12 GiB。reserved 余量仅约 0.43 GiB，应按原门槛停止而非降低模型、batch 或精度。存储可按三份 payload、日志、实测暂存加 12 GiB 空余约 36 GiB 规划；采用全部精确分数 DB 硬上限则约 63 GiB，再另留文件系统、临时文件余量。这些不包含原始数据重复存储，不自动放宽原 7 天/32 TiB 等执行硬预算。

已登记 2026-10-14 00:26:59 UTC 的 nvlddmkm 153 / LiveKernelEvent，对应 1,795 次已核验但未提交到该轮 LAST 的更新消耗；根因未确立。Windows Job 不能保证操作系统/GPU 驱动崩溃后的状态持久化。未来应保持供电和通风、记录温度/驱动/事件，仍禁止自动重试或退款。安全暂停应等完整 epoch、完整开发验证及 LAST 提交后退出，B1 常态剩余等待可能超过一小时，慢轮可更久；紧急停止后需重新核对具体 LAST 和额度。

9 论文可用结论及下一步验证目标

目前支持 H-O 的单 seed 开发性方向证据；H-Q 仅 B0 较明确，B1 尚不稳健。时序输入有总体排序和平均 CP 的贡献，但欠覆盖、强雨层与高条件上尾风险仍存在。未建立全面优越性、独立物理验证、未来年份泛化、确认性显著性或严格业务近实时能力。IMERG V07 Final 仍是回顾性监督参考，不是业务可获取延迟证据。

剩余预定义 seeds 2027/2028 最应检验：H-O 方向是否跨初始化稳定；H-Q 是否为 B0 特有或可复现于 B1；覆盖改善是否伴随 CP/强雨/上尾副作用；B1 总体贡献能否在三个 seed 稳定而不牺牲最高雨强。应逐 seed 报告，再讨论初始化变异，不把三个 seed 当作新增独立天气样本。禁止根据当前六组修改阈值、资格、层边界或实验配方。本轮没有启动剩余十二组。

10 复现文件与审查记录

入口为 `analysis/analyze.py`、`plot.py`、`report.py`。十个图均附 SVG/PDF/600 dpi PNG，所有表格保留 CSV 全精度。分析以 Git `dbccf220e8e88178388433e3d69e4e0e9682d652` 为公开证据基线；发布 commit 另见交付记录。输入、代码及图表的 SHA 见 manifest。本轮仅重新汇总已发表统计及登记资源日志；AUROC/AP 沿用精确分数并列口径的已发布值，没有重新读取全像元 score 数据库或运行推理。完整 span 分布、逐位置概率与极端 q32 的联合诊断、独立站点/雷达核实均未补造。

初次分析环境版本元数据读取因隔离目录 ACL 失败；同一脚本以获准正常用户令牌重跑后通过，没有降低数值容差。首遍备份搜索上限收据及修复记录保留。本轮新优化器更新、模型推理、原始观测内容读取均为零；权重仅作 SHA。历史恢复治理和 2025 路径属性未计数事实仍保留，不追认、不追溯清零。